

Rice Classification

Contexto

El grano de arroz constituye el segundo alimento más utilizado en el mundo después del trigo, se puede decir que casi la mitad de la población mundial depende de este cereal. El arroz es una gran fuente de energía y fortalece el sistema inmunológico ayudando a la digestión, además de ser bajos en grasa y ricos en sodio, aportando hidratos de carbono y proteínas de origen vegetal.

Cabe mencionar que en el mundo existen muchas variedades genéticas de arroz, los cuales se diferencian entre sí por características como lo es la textura, la forma, el color y aroma. Estas características son específicas y distinguen cada uno de los tipos de arroz, por lo cuál es factible clasificar el arroz de acuerdo a su tipo.

Los tipos de arroz con los que se trabajará en este proyecto son los siguientes: Arborio, Basmati, Ipsala, Jasmine y Karacadag. Cada una de estas variedades de arroz tiene sus propios usos culinarios y características únicas.

Objetivos

- Entrenar un modelo de redes neuronales convolucionales lo bastante robusto que pueda clasificar con precisión los diferentes granos de arroz en su respectivas categorías.
- Aplicar y entender en un problema del mundo real cada uno de los conocimientos adquiridos en las clases.

Dataset

El dataset cuenta con un total de 75000 imágenes, 15000 imágenes por cada uno de los tipos de arroz. Cada una de esta imágenes tiene un tamaño de 250 por 250 bytes y un tipo de color RGB. En las imágenes se puede observar cada uno de los diferentes tipos de granos de arroz de arroz en diversas formas, tamaños y posiciones.

Métricas de desempeño

Las métricas de desempeño que se utilizarán para evaluar la solución propuesta son las siguientes:

- **Accuracy:** Proporción de imágenes que el modelo clasifica correctamente entre el total de imágenes. Esta métrica mide la exactitud global del modelo.
- **Loss:** Proporción de error entre las predicciones del modelo y las etiquetas reales.
- **Confusion matrix:** Número de imágenes que el modelo clasifica correctamente e incorrectamente por cada tipo de arroz. Esta métrica permite visualizar el desempeño del modelo por clase y detectar posibles confusiones entre ellas.

- **Precision:** Proporción de imágenes que el modelo clasifica correctamente como un tipo de arroz entre el total de imágenes que clasifica como ese tipo. Esta métrica mide la precisión del modelo por clase.
- **Recall:** Proporción de imágenes que el modelo clasifica correctamente como un tipo de arroz entre el total de imágenes que realmente son de ese tipo. Esta métrica mide la exhaustividad del modelo por clase.
- **F1-score:** Es la media armónica entre la precisión y el recall. Esta métrica mide el balance entre la precisión y la exhaustividad del modelo por clase.

Las métricas de negocio que se utilizarán para evaluar el impacto del proyecto son las siguientes:

- **Tiempo:** Tiempo que se tarda en clasificar un lote de imágenes con el modelo. Esta métrica mide la eficiencia del proyecto en comparación con la clasificación manual.

Referencias y resultados previos

[Rice Classification 🌾 | 99% Accuracy](#) En este notebook, se utiliza el aprendizaje por transferencia con MobileNetV2 para crear un modelo de clasificación. Se usa un modelo secuencial de Keras y se evalúa el modelo usando una matriz de confusión y las métricas de precisión, exhaustividad, f1-score, que miden el rendimiento del modelo por clase, así como el accuracy y loss, que miden el rendimiento global del modelo. El notebook muestra un accuracy del 99% después de 10 épocas.

[Rice Image Classification | CNN | 0.99](#) La solución propuesta en el notebook presenta un modelo que implementa capas de convolución, pooling y flattening para preparar los datos de entrada, y una capa fully connected para clasificar las imágenes. Este enfoque secuencial y jerárquico permite que el modelo aprenda atributos complejos de las imágenes. También se evalúa el modelo usando las siguientes métricas de desempeño: matriz de confusión, precisión, exhaustividad, f1-score, accuracy y loss.

[Rice prediction with Convolutional Neural Network](#) En esta solución se utilizan cinco modelos diferentes que implementan capas convolucionales, pooling, flattening, fully connected y función de activación sigmoideal. Se evalúa su desempeño utilizando métricas como matriz de confusión, precisión, recall, puntuación F1, accuracy y loss. El modelo más efectivo fue aquel que utiliza dos capas convolucionales, tres capas de pooling, una capa de flattening y una capa fully connected, con función de activación sigmoideal y entrenado durante 27 épocas, logrando una exactitud de 0.99.

Bibliografía.

- [1] Rice Image Dataset. (2022, April 3). Kaggle. <https://www.kaggle.com/datasets/muratkokludataset/rice-image-dataset>
- [2] DATASETS. (n.d.). <https://www.muratkoklu.com/datasets/>
- [3] Iranzo, A., & Iranzo, A. (2023, September 15). Tipos de Arroz: Características y Diferencias. Chovi. <https://www.chovi.com/en/blog/nutricion/tipos-arroz/>
- [4] Ayessa. (2022). Rice Classification 🌾 | 99% accuracy. Kaggle. <https://www.kaggle.com/code/ayessa/rice-classification-99-accuracy/notebook>
- [5] Rezasemyari. (2023). Rice Image Classification | CNN | 0.99. Kaggle. <https://www.kaggle.com/code/rezasemyari/rice-image-classification-cnn-0-99>
- [6] Hashemi. (2023). Rice prediction with convolutional neural network. Kaggle. <https://www.kaggle.com/code/hashemi221022/rice-prediction-with-convolutional-neural-network>